Sandbox e previsão de recursos com aprendizado de máquina

INF0336 SISTEMAS OPERACIONAIS

INF
INSTITUTO DE INFORMÁTICA
UFG
UNIVERSIDADE FEDERAL DE GOIÁS

INF
INSTITUTO DE INFORMÁTICA

Equipe Futhienas

Wender Viana Faria Santos

William Félix Ferreira Alves da Silva

Wryel Teodoro de Morais

Lourenço Tabosa Paniago

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

O problema: acessos e recursos em excesso

Como executar um script Python com apenas o necessário para a tarefa?

ACESSO A ARQUIVOS



Ler dados fora da tarefa.

Alterar arquivos de entrada.

Gravar em caminhos indevidos.

CONSUMO DE RECURSOS



Usar memória em excesso.

Executar por tempo excessivo.

Gerar arquivos sem limite.

Precisamos restringir acessos e definir limites de execução.

Objetivo e proposta

Recomendar limites menores, preservando a correção e a autorização externa.

O planejador recomenda

Estima memória e duração
a partir do código e da entrada.

A política autoriza

Restringe arquivos e aplica
os tetos definidos pelo operador.

Até a semana 2: executor, coleta, modelo e comparação integrados.

A estimativa do modelo sempre passa pela política de execução.

Fluxograma do experimento

A coleta e o treino ocorrem antes da comparação dos métodos.



Treinamento offline; autorização aplicada a cada execução.

Como o primeiro modelo aprende

32 tarefas: quatro tipos, com oito variações de tamanho em cada tipo.

Etapa	Dados usados no piloto
Coleta	32 tarefas × 2 execuções = 64 medições
Entrada do modelo	11 características do código e da entrada
Saída do modelo	Pico de memória virtual e duração
Divisão dos dados	24 tarefas para treino e 8 para teste

Tipos de tarefa

Alocação: criar blocos de memória.

Cálculo: realizar operações numéricas.

Leitura: ler arquivos de texto.

Escrita: gravar arquivos.

Os quatro tipos aparecem tanto no treino quanto no teste.

Comparação nas oito tarefas de teste

Fixo: orçamento constante. Heurística: regras. ML: árvore treinada.

Método	Execuções corretas	Limite médio de memória virtual (MiB)
Fixo	8/8	128
Heurística	8/8	35
ML	8/8	42,25

8 tarefas × 3 métodos = 24 reexecuções de avaliação.

Todos preservaram a correção; a heurística recomendou o menor limite.

Limite de memória virtual por processo não é consumo de RAM física.

Tempos e consumo medidos

Médias das oito tarefas por método; memória: média dos picos por execução.

Método	Tempo decorrido (ms)	Tempo de CPU (ms)	Pico médio de RAM (MiB)
Fixo	49,73	48,27	12,24
Heurística	51,16	49,49	12,28
ML	49,18	47,60	12,35

Tempos e memória semelhantes; sem vantagem demonstrada do ML.

Uma execução por método e tarefa; diferenças pequenas exigem mais repetições.

Planejamento para as próximas semanas

Mais diversidade, seleção na validação e teste com tipos de tarefa reservados.

Semana	Objetivo	Entrega prevista
3	Diversificar os dados	Novas tarefas de diferentes tipos
4	Calibrar e comparar	Modelo e margens selecionados na validação
5	Avaliar e concluir	Teste com tipos inéditos e reprodução

Referências

Menor privilégio

Saltzer e Schroeder (1975) — The protection of information in computer systems.

Predição de recursos

Kwon et al. (2013) — Mantis. USENIX ATC, p. 297–308.

Aprendizado de máquina

Pedregosa et al. (2011) — Scikit-learn. JMLR, v. 12, p. 2825–2830.

Modelo e avaliação

Scikit-learn — DecisionTreeRegressor; Common pitfalls.

Isolamento e limites

Bubblewrap — documentação do projeto; Linux — getrlimit(2).

INF
INSTITUTO DE INFORMÁTICA

Dúvidas?

UFG
UNIVERSIDADE FEDERAL DE GOIÁS